mod195168les

February 9, 2023

1 Tests des modèles (cnn, rnn, bert) avec Melusine

1.0.1 Importation des packages et fonction nécessaires

```
[1]: from melusine.nlp tools.phraser import phraser on body, Phraser
     from melusine.utils.transformer_scheduler import TransformerScheduler
     from melusine.prepare email.manage transfer reply import
      ⇔check_mail_begin_by_transfer
     from melusine.prepare_email.manage_transfer_reply import_
      →update_info_for_transfer_mail
     from melusine.prepare email.manage transfer reply import add boolean transfer
     from melusine.prepare_email.manage_transfer_reply import add_boolean_answer
     from melusine.prepare email.body header extraction import extract last body
     from melusine.prepare_email.cleaning import clean_body
     from melusine.prepare email.build historic import build historic
     from melusine.prepare_email.mail_segmenting import structure_email
     from melusine.nlp_tools.tokenizer import Tokenizer
     from melusine.summarizer.keywords_generator import KeywordsGenerator
     from sklearn.pipeline import Pipeline
     import ast
     from melusine.prepare_email.metadata_engineering import MetaExtension
     from melusine.prepare_email.metadata_engineering import MetaDate
     from melusine.prepare_email.metadata_engineering import MetaAttachmentType
     from melusine.prepare email.metadata engineering import Dummifier
     from melusine.nlp tools.embedding import Embedding
     from sklearn.preprocessing import LabelEncoder
     from melusine.models.train import NeuralModel
     from melusine.models.neural architectures import cnn model, bert model,
      →rnn_model, transformers_model
     import joblib as jl
     import pandas as pd
```

C:\Users\JUFL\Anaconda3\lib\site-packages\gensim\similarities__init__.py:15: UserWarning: The gensim.similarities.levenshtein submodule is disabled, because the optional Levenshtein package https://pypi.org/project/python-Levenshtein/ is unavailable. Install Levenhstein (e.g. `pip install python-Levenshtein`) to suppress this warning.

```
warnings.warn(msg)
```

1.0.2 Importation du fichier csv de tests (mails issus d'une boite Verlingue)

```
[2]: df_emails = pd.read_csv(r"filepath", delimiter=";")
     df_emails
[3]:
                                                      header
     0
             Probl me connexion Prod et pr prod postgresql
         TR: package open source traitement des emails ...
     1
     2
         RE7_Coverlife/TALEND_BI_COVERLIFE/SID_CVLF_CHA...
     3
                                DWH ADP OK - GENERATION_PRD
     4
         RE7_Coverlife/TALEND_BI_COVERLIFE/SID_CVLF_CHA...
     64
                    TR: Gestion de la BAL Verlingue Connect
     65
                                 DWH ADP OK - VERLINGUE_PRD
     66
                                DWH ADP OK - GENERATION_PRD
         [MEP de Version MAJEURE 2021.V2.0] - [FIN DE R...
     67
         RE7_Coverlife/TALEND_BI_COVERLIFE/SID_CVLF_CHA...
                                                                     date \
                                                        body
     0
         Bonjour, \n\n \n\nLa production et la pr produc...
                                                            14/06/2021
          \n\n \n\nDe : Marie Leduc <mleduc@quantmetry...
     1
                                                           14/06/2021
     2
         Le traitement SID_CVLF_CHARGEMENT ne s'est pas...
                                                            14/06/2021
         Bonjour, \n\nLa mise disposition des donn es ...
     3
         Le traitement SID_CVLF_CHARGEMENT ne s'est pas...
                                                             14/06/2021
     . .
          \n\n \n\n----Rendez-vous d'origine----\nDe ...
     64
                                                             18/06/2021
     65
         Bonjour, \n\nLa mise
                               disposition des donn es ...
                                                           19/06/2021
         Bonjour, \n\nLa mise
                                disposition des donn es ...
     66
                                                            19/06/2021
         Information de fin de RECETTE post-MEP\n\nde l...
     67
                                                            19/06/2021
         Le traitement SID_CVLF_CHARGEMENT ne s'est pas...
                                                            19/06/2021
                                     from
     0
                           Le Moal Mikael
                  L'hotellier Jean-Marie
     1
         DSI-suivi-production@netdmx.com
     2
     3
                   no-reply@verlingue.fr
     4
         DSI-suivi-production@netdmx.com
     64
                  L'hotellier Jean-Marie
     65
                   no-reply@verlingue.fr
     66
                   no-reply@verlingue.fr
     67
                            Fralin Thomas
     68
         DSI-suivi-production@netdmx.com
                                                                                 Cci
     0
                                               DSI Infra DBA DSI Data Factory
```

```
1
                            Allain Marc; Fresnel Julien
                                                                        {\tt NaN}
                                                                             NaN
2
                                       DSI Data Factory
                                                                         NaN
                                                                              NaN
3
    DSI Data Factory; Generation Statistiques; Suppo...
                                                                      NaN NaN
4
                                       DSI Data Factory
                                                                         NaN
                                                                              NaN
64
                                         Fresnel Julien
                                                                              NaN
                                                                        NaN
                       DSI Data Factory; jvieaud@asi.fr
65
                                                                        NaN NaN
66
    DSI Data Factory; Generation Statistiques; Suppo...
                                                                      NaN NaN
    MOA Verlingue; webmoa; DSSI Verlingue; DSI Presta...
67
                                                          DSI Management NaN
68
                                       DSI Data Factory
                                                                        NaN NaN
    Cat gories Crit re de diffusion Importance attachment
                                                                       label
0
           NaN
                           Normal(e)
                                       Normal(e)
                                                          NaN
                                                                   production
1
           NaN
                           Normal(e) Normal(e)
                                                          NaN
                                                                           rdv
2
           NaN
                           Normal(e) Normal(e)
                                                          NaN
                                                                   production
3
           NaN
                           Normal(e) Normal(e)
                                                          NaN
                                                                datawarehouse
                           Normal(e) Normal(e)
4
           NaN
                                                          NaN
                                                                   traitement
64
           NaN
                           Normal(e) Normal(e)
                                                          NaN
                                                                           rdv
           NaN
                           Normal(e) Normal(e)
                                                                datawarehouse
65
                                                          NaN
                           Normal(e) Normal(e)
66
           NaN
                                                          {\tt NaN}
                                                                datawarehouse
                           Normal(e) Normal(e)
67
           NaN
                                                          NaN
                                                                   production
68
           NaN
                           Normal(e) Normal(e)
                                                          {\tt NaN}
                                                                   traitement
```

[69 rows x 12 columns]

1.0.3 Traitement sur les mails (lire notebook "Test melusine.ipynb")

```
phraser = Phraser()
    phraser.train(df_emails)
    phraser.save(r'...\phraser.pickle')
    PhraserTransformer =
     df_emails = PhraserTransformer.fit_transform(df_emails)
    tokenizer = Tokenizer(input_column='clean_body')
    df_emails = tokenizer.fit_transform(df_emails)
    keywords_generator = KeywordsGenerator(n_max_keywords=5)
    df_emails = keywords_generator.fit_transform(df_emails)
    pretrained_embedding = Embedding(input_column='clean_body', workers=1,_
     →min_count=5)
    pretrained_embedding.train(df_emails)
    pretrained_embedding.save(r'....\embedding.pickle')
    Metadatapipeline = Pipeline([('MetaExtension', MetaExtension()), ('MetaDate', __
     MetaDate()), ('MetaAttachmentType', MetaAttachmentType()), ('Dummifier', |
     →Dummifier())])
    df_meta = Metadatapipeline.fit_transform(df_emails)
    23/06 08:55 - melusine.nlp_tools.phraser - INFO
    Start training for colocation detector
    23/06 08:55 - melusine.nlp_tools.phraser - INFO
    Done.
    23/06 08:55 - melusine.nlp_tools.embedding - INFO - Start training for embedding
    23/06 08:55 - melusine.nlp_tools.embedding - INFO - Done.
[5]: df_meta
[5]:
        extension_0
                     extension_1 extension_2 extension_3 attachment_type_0
    0
                               0
                                             0
                                                          0
                  1
                                                                             1
                               0
    1
                  1
                                             0
                                                          0
                                                                             1
    2
                  0
                               1
                                             0
                                                          0
                                                                             1
    3
                  0
                                             1
                                                                             1
                               0
                                             0
                                                          0
                                                                             1
    64
```

65	0	0	1	0	1
66	0	0	1	0	1
67	1	0	0	0	1
68	0	1	0	0	1

[69 rows x 5 columns]

[6]: df_emails

```
[6]:
                                                      header \
     0
             Probl me connexion Prod et pr prod postgresql
     1
         TR: package open source traitement des emails ...
     2
         RE7_Coverlife/TALEND_BI_COVERLIFE/SID_CVLF_CHA...
                                DWH ADP OK - GENERATION_PRD
     3
     4
         RE7_Coverlife/TALEND_BI_COVERLIFE/SID_CVLF_CHA...
     64
                   TR: Gestion de la BAL Verlingue Connect
                                 DWH ADP OK - VERLINGUE_PRD
     65
     66
                                DWH ADP OK - GENERATION_PRD
     67
         [MEP de Version MAJEURE 2021.V2.0] - [FIN DE R...
         RE7_Coverlife/TALEND_BI_COVERLIFE/SID_CVLF_CHA...
                                                        body date \
     0
         Bonjour, \n\n \n\nLa production et la pr produc...
                                                           NaT
     1
          \n\n \n\nDe : Marie Leduc <mleduc@quantmetry...
     2
         Le traitement SID_CVLF_CHARGEMENT ne s'est pas...
         Bonjour, \n\nLa mise disposition des donn es ...
     4
         Le traitement SID_CVLF_CHARGEMENT ne s'est pas...
                                                            NaT
          \n\n \n\n----Rendez-vous d'origine----\nDe ... NaT
     64
     65
         Bonjour, \n\nLa mise
                               disposition des donn es ... NaT
         Bonjour, \n\nLa mise
                               disposition des donn es ... NaT
     66
         Information de fin de RECETTE post-MEP\n\nde l... NaT
     67
         Le traitement SID_CVLF_CHARGEMENT ne s'est pas... NaT
                                     from
     0
                           Le Moal Mikael
     1
                  L'hotellier Jean-Marie
     2
         DSI-suivi-production@netdmx.com
     3
                   no-reply@verlingue.fr
     4
         DSI-suivi-production@netdmx.com
     64
                  L'hotellier Jean-Marie
     65
                   no-reply@verlingue.fr
     66
                   no-reply@verlingue.fr
     67
                            Fralin Thomas
         DSI-suivi-production@netdmx.com
     68
```

```
Cc Cci \
                                                      to
                                          DSI Infra DBA DSI Data Factory
0
                                                                             NaN
1
                            Allain Marc; Fresnel Julien
                                                                             NaN
2
                                                                        NaN NaN
                                       DSI Data Factory
3
    DSI Data Factory; Generation Statistiques; Suppo...
                                                                      NaN NaN
4
                                       DSI Data Factory
                                                                        \mathtt{NaN}
                                                                             NaN
. .
64
                                         Fresnel Julien
                                                                        NaN
                                                                             NaN
65
                       DSI Data Factory; jvieaud@asi.fr
                                                                        NaN
                                                                             NaN
    DSI Data Factory; Generation Statistiques; Suppo...
66
                                                                      NaN NaN
67
    MOA Verlingue; webmoa; DSSI Verlingue; DSI Presta...
                                                          DSI Management NaN
68
                                       DSI Data Factory
                                                                        NaN NaN
    Cat gories Crit re de diffusion Importance ... \
0
           NaN
                           Normal(e)
                                       Normal(e)
1
           NaN
                           Normal(e)
                                       Normal(e)
2
           NaN
                           Normal(e)
                                       Normal(e)
3
           NaN
                           Normal(e)
                                       Normal(e)
4
           NaN
                           Normal(e)
                                       Normal(e)
                                         ... ...
64
           NaN
                           Normal(e)
                                       Normal(e)
65
           NaN
                           Normal(e)
                                       Normal(e)
66
           NaN
                           Normal(e)
                                       Normal(e)
67
                           Normal(e)
                                       Normal(e)
           NaN
68
           NaN
                           Normal(e)
                                       Normal(e)
                                        structured_body \
0
    [{'meta': {'date': None, 'from': None, 'to': N...
    [{'meta': {'date': None, 'from': 'Marie Leduc ...
1
2
    [{'meta': {'date': None, 'from': None, 'to': N...
    [{'meta': {'date': None, 'from': None, 'to': N...
3
    [{'meta': {'date': None, 'from': None, 'to': N...
4
. .
64
    [{'meta': {'date': None, 'from': None, 'to': N...
65
    [{'meta': {'date': None, 'from': None, 'to': N...
    [{'meta': {'date': None, 'from': None, 'to': N...
66
    [{'meta': {'date': None, 'from': None, 'to': N...
67
    [{'meta': {'date': None, 'from': None, 'to': N...
68
                                              last body \
0
     La production et la proproduction PostgreSQL ...
    Envoy: mardi 8 juin 2021 08:37
1
                                        : L'hotelli...
2
    Le traitement SID_CVLF_CHARGEMENT ne s'est pas...
3
    La mise
              disposition des donn es du jour dans...
4
    Le traitement SID_CVLF_CHARGEMENT ne s'est pas...
```

```
64
                      ----Rendez-vous d'origine----
65
             disposition des donn es du jour dans...
   La mise
              disposition des donn es du jour dans...
67
    Information de fin de RECETTE post-MEP de la V...
   Le traitement SID_CVLF_CHARGEMENT ne s'est pas...
                                             clean body \
0
    la production et la prproduction postgresql se...
                           flag_time_ : l'hotellie...
    envoy: flag date
1
    le traitement sid_cvlf_chargement ne s'est pas...
2
    la mise disposition des donnes du jour dans le...
    le traitement sid_cvlf_chargement ne s'est pas...
4
. .
64
                                 rendez-vous d'origine
    la mise disposition des donnes du jour dans le...
65
66
    la mise disposition des donnes du jour dans le...
    information de fin de recette post-mep de la v...
67
    le traitement sid_cvlf_chargement ne s'est pas...
                                                 tokens \
0
    [production, prproduction, postgresql, semble,...
    [envoy, flag_date_, flag_time_, hotellier, fla...
1
2
    [traitement, sid_cvlf_chargement, termin, corr...
3
    [mise, disposition, donnes, jour, datawarehous...
    [traitement, sid_cvlf_chargement, termin, corr...
4
64
                                [rendez-vous, origine]
    [mise, disposition, donnes, jour, datawarehous...
65
66
    [mise, disposition, donnes, jour, datawarehous...
    [information, fin, recette, post-mep, version,...
67
    [traitement, sid_cvlf_chargement, termin, corr...
68
                                               keywords extension hour min \
0
    [prproduction, flag_date_, vers, flag_time_, c...
                                                              0 NaN NaN
                                                              0 NaN NaN
1
    [flag_date_, flag_time_, hotellier, flag_name_...
2
    [traitement, sid_cvlf_chargement, suivi, produ...
                                                              1 NaN NaN
        [atlas, nombre, flag_cp_, flag_date_, pouvez]
                                                                2 NaN NaN
3
4
    [traitement, sid_cvlf_chargement, suivi, produ...
                                                              1 NaN NaN
64
                                              [origine]
                                                                0 NaN NaN
     [nombre, flag_cp_, flag_date_, gnration, pouvez]
65
                                                                2 NaN NaN
66
    [nombre, flag_phone_, flag_cp_, flag_date_, po...
                                                              2 NaN NaN
                                                                O NaN NaN
67
       [flag_time_, tnr, flag_name_, iard, flag_url_]
68
    [traitement, sid_cvlf_chargement, suivi, produ...
                                                              1 NaN NaN
   dayofweek attachment_type
0
         NaN
                          [0]
```

```
1
                                [0]
           NaN
2
                                [0]
           NaN
3
           NaN
                                [0]
4
                                [0]
           NaN
                                [0]
64
           NaN
                                [0]
65
           NaN
66
           NaN
                                [0]
                                [0]
67
           NaN
68
           NaN
                                [0]
```

[69 rows x 26 columns]

1.0.4 Modèles NLP

Dans le package melusine il existe plusieurs modèles nlp :

- Le modèle RNN : il est utilisé traditionnellement pour les données textuelles.
- Le modèle CNN : modèle un peu moins précis que le rnn, il est cependant plus rapide et demande encore moins de ressources mémoire
- Le **Transformers model** : modèle aussi précis que le rnn, plus rapide que ce dernier et qui demande autant de ressource mémoire
- Le modède CamemBert : architecture bert
- Le modèle FlauBert : architecture bert

Voici comment appeler chaque modèle :

On utilise la méthode LabelEncoder qui va transformer des str en int

```
[7]: | X = pd.concat([df_emails['clean_body'], df_meta], axis=1)
     y = df emails['label']
     le = LabelEncoder()
     y = le.fit_transform(y)
     nn_model = NeuralModel(architecture_function= cnn_model,__
      opretrained_embedding=pretrained_embedding, text_input_column_

¬="clean_body",meta_input_list=['extension', 'dayofweek','hour', 'min',

      ⇔'attachment_type'], n_epochs=10)
     nn_model2 = NeuralModel(architecture_function= rnn_model,__
      opretrained_embedding=pretrained_embedding, text_input_column_
      -="clean_body",meta_input_list=['extension', 'dayofweek','hour', 'min', ω

¬'attachment_type'], n_epochs=10)
     nn_model3 = NeuralModel(architecture_function= rnn_model,_
      opretrained_embedding=pretrained_embedding, text_input_column_
      -="clean_body",meta_input_list=['extension', 'dayofweek','hour', 'min', ω

¬'attachment_type'], n_epochs=10)
```

On effectue l'entrainement avec la méthode fit

```
Epoch 2/10
0.1739
Epoch 3/10
0.1304
Epoch 4/10
0.2029
Epoch 5/10
0.2464
Epoch 6/10
0.1739
Epoch 7/10
0.2899
Epoch 8/10
```

```
0.2609
Epoch 9/10
0.3043
Epoch 10/10
0.2464
----rnn model-----
Epoch 1/10
0.1304
Epoch 2/10
0.1594
Epoch 3/10
0.2754
Epoch 4/10
0.2319
Epoch 5/10
0.2464
Epoch 6/10
0.2609
Epoch 7/10
0.2464
Epoch 8/10
0.2464
Epoch 9/10
0.2609
Epoch 10/10
-----transformers_model-----
Epoch 1/10
0.1304
Epoch 2/10
0.0870
Epoch 3/10
0.2609
```

```
Epoch 4/10
0.2174
Epoch 5/10
0.2754
Epoch 6/10
0.2609
Epoch 7/10
0.2319
Epoch 8/10
Epoch 9/10
0.2754
Epoch 10/10
0.2899
-----CamemBert model-----
```

Some layers from the model checkpoint at jplu/tf-camembert-base were not used when initializing TFCamembertModel: ['lm_head']

- This IS expected if you are initializing TFCamembertModel from the checkpoint of a model trained on another task or with another architecture (e.g. initializing a BertForSequenceClassification model from a BertForPretraining model).
- This IS NOT expected if you are initializing TFCamembertModel from the checkpoint of a model that you expect to be exactly identical (initializing a BertForSequenceClassification model from a BertForSequenceClassification model). All the layers of TFCamembertModel were initialized from the model checkpoint at jplu/tf-camembert-base.

If your task is similar to the task the model of the checkpoint was trained on, you can already use TFCamembertModel for predictions without further training.

-----FlauBert_model-----

Some layers from the model checkpoint at jplu/tf-flaubert-base-cased were not used when initializing TFFlaubertModel: ['pred_layer_._proj']

- This IS expected if you are initializing TFFlaubertModel from the checkpoint of a model trained on another task or with another architecture (e.g. initializing a BertForSequenceClassification model from a BertForPretraining model).
- This IS NOT expected if you are initializing TFFlaubertModel from the checkpoint of a model that you expect to be exactly identical (initializing a

BertForSequenceClassification model from a BertForSequenceClassification model). All the layers of TFFlaubertModel were initialized from the model checkpoint at jplu/tf-flaubert-base-cased.

If your task is similar to the task the model of the checkpoint was trained on, you can already use TFFlaubertModel for predictions without further training.

Maintenant que les modèles sont entrainés nous allons les tester sur le même jeu de données afin de voir si les prédictions sont correctes. (Et histoire de montrer le fonctionnement)

1.0.5 Tests

Utilisons le même jeu de données mais non-labellisées :

```
[9]: df_emails_tests = pd.read_csv(r"...\testtrain2.CSV", delimiter=";")
[10]: df_emails_tests
[10]:
                                                    header \
     0
             Probl me connexion Prod et pr prod postgresql
         TR: package open source traitement des emails ...
     1
     2
         RE7_Coverlife/TALEND_BI_COVERLIFE/SID_CVLF_CHA...
     3
                               DWH ADP OK - GENERATION_PRD
     4
         RE7_Coverlife/TALEND_BI_COVERLIFE/SID_CVLF_CHA...
     64
                   TR: Gestion de la BAL Verlingue Connect
     65
                                DWH ADP OK - VERLINGUE_PRD
     66
                               DWH ADP OK - GENERATION_PRD
          [MEP de Version MAJEURE 2021.V2.0] - [FIN DE R...
     67
         RE7_Coverlife/TALEND_BI_COVERLIFE/SID_CVLF_CHA...
                                                      body
                                                                  date \
         Bonjour, \n\n \n\nLa production et la pr produc...
     0
                                                         14/06/2021
          \n\n \n\nDe : Marie Leduc <mleduc@quantmetry... 14/06/2021
     1
     2
         Le traitement SID_CVLF_CHARGEMENT ne s'est pas... 14/06/2021
         Bonjour, \n\nLa mise disposition des donn es ... 14/06/2021
     3
     4
         Le traitement SID_CVLF_CHARGEMENT ne s'est pas...
                                                          14/06/2021
          64
         Bonjour, \n\nLa mise
                              disposition des donn es ... 19/06/2021
     65
         Bonjour, \n\nLa mise
                               disposition des donn es ...
     66
                                                         19/06/2021
         Information de fin de RECETTE post-MEP\n\nde 1... 19/06/2021
     67
         Le traitement SID_CVLF_CHARGEMENT ne s'est pas... 19/06/2021
                                    from \
     0
                          Le Moal Mikael
     1
                  L'hotellier Jean-Marie
```

```
2
    DSI-suivi-production@netdmx.com
3
              no-reply@verlingue.fr
4
    DSI-suivi-production@netdmx.com
. .
             L'hotellier Jean-Marie
64
65
              no-reply@verlingue.fr
              no-reply@verlingue.fr
66
67
                       Fralin Thomas
    DSI-suivi-production@netdmx.com
68
                                                      to
                                                                          Cc Cci
0
                                          DSI Infra DBA DSI Data Factory
                                                                              NaN
1
                            Allain Marc; Fresnel Julien
                                                                              NaN
                                                                        NaN NaN
2
                                       DSI Data Factory
3
    DSI Data Factory; Generation Statistiques; Suppo...
                                                                      NaN NaN
4
                                       DSI Data Factory
                                                                         NaN
                                                                              NaN
. .
64
                                         Fresnel Julien
                                                                         NaN
                                                                              NaN
65
                       DSI Data Factory; jvieaud@asi.fr
                                                                        NaN NaN
    DSI Data Factory; Generation Statistiques; Suppo...
66
                                                                      {\tt NaN}
                                                                           NaN
    MOA Verlingue; webmoa; DSSI Verlingue; DSI Presta...
67
                                                          DSI Management
                                                                           NaN
                                       DSI Data Factory
68
                                                                         NaN NaN
    Cat gories Crit re de diffusion Importance attachment
0
           NaN
                           Normal(e)
                                       Normal(e)
                                                          NaN
1
           NaN
                           Normal(e) Normal(e)
                                                          NaN
                           Normal(e) Normal(e)
2
           NaN
                                                          NaN
3
                           Normal(e) Normal(e)
           NaN
                                                          NaN
4
           NaN
                           Normal(e)
                                       Normal(e)
                                                          NaN
                           Normal(e)
                                       Normal(e)
64
           NaN
                                                          NaN
                           Normal(e)
65
                                       Normal(e)
           NaN
                                                          NaN
                           Normal(e)
                                       Normal(e)
66
           NaN
                                                          NaN
67
           NaN
                           Normal(e)
                                       Normal(e)
                                                          NaN
           NaN
                           Normal(e)
                                       Normal(e)
                                                          NaN
```

On réalise les mêmes traitements que d'habitude :

[69 rows x 11 columns]

```
ManageTransformer = U

TransformerScheduler(functions_scheduler=[(check_mail_begin_by_transfer, U)
None, ['is_begin_by_transfer']), (update_info_for_transfer_mail, None, U)
None), (add_boolean_answer, None, ['is_answer']), (add_boolean_transfer, U)
None, ['is_transfer'])])

df_emails_tests = ManageTransformer.fit_transform(df_emails_tests)
```

```
SegmentingTransformer =
      →TransformerScheduler(functions_scheduler=[(build_historic,None,_
      →['structured_historic']), (structure_email, None, ['structured_body'])])
     df_emails_tests = SegmentingTransformer.fit_transform(df_emails_tests)
     Cleaning = TransformerScheduler(functions_scheduler=[(extract_last_body, None, __
      df_emails_tests = Cleaning.fit_transform(df_emails_tests)
     tokenizer = Tokenizer(input_column='clean_body')
     df_emails_tests = tokenizer.fit_transform(df_emails_tests)
     MetaDate()), ('MetaAttachmentType', MetaAttachmentType()), ('Dummifier', |
      →Dummifier())])
     df_meta_tests = Metadatapipeline.fit_transform(df_emails_tests)
[12]: df_meta_tests
                     extension__1 extension__2 extension__3 attachment_type__0
[12]:
         extension__0
     0
                   1
     1
                   1
                                0
                                             0
                                                          0
                                                                            1
     2
                   0
                                             0
                                                          0
                                                                            1
                                1
     3
                   0
                                0
                                             1
                                                          0
                                                                            1
     4
                   0
                                                          0
                                                                            1
     64
                   1
                                0
                                             0
                                                          0
                                                                            1
     65
                   0
                                0
                                             1
                                                          0
                                                                            1
     66
                   0
                                0
                                             1
                                                          0
                                                                            1
     67
                                             0
                                                          0
                                                                            1
                   1
     68
                                                                            1
     [69 rows x 5 columns]
[13]: df_emails_tests
[13]:
                                                 header \
     0
            Probl me connexion Prod et pr prod postgresql
         TR: package open source traitement des emails ...
     1
         RE7_Coverlife/TALEND_BI_COVERLIFE/SID_CVLF_CHA...
     2
                             DWH ADP OK - GENERATION_PRD
     3
     4
         RE7_Coverlife/TALEND_BI_COVERLIFE/SID_CVLF_CHA...
```

```
64
              TR: Gestion de la BAL Verlingue Connect
65
                            DWH ADP OK - VERLINGUE_PRD
66
                           DWH ADP OK - GENERATION_PRD
67
    [MEP de Version MAJEURE 2021.V2.0] - [FIN DE R...
    RE7_Coverlife/TALEND_BI_COVERLIFE/SID_CVLF_CHA...
68
                                                    body date \
0
    Bonjour, \n\n \n\nLa production et la pr produc...
                                                       NaT
     \n\n \n\nDe : Marie Leduc <mleduc@quantmetry...
1
2
    Le traitement SID_CVLF_CHARGEMENT ne s'est pas...
3
    Bonjour, \n\nLa mise disposition des donn es ... NaT
    Le traitement SID_CVLF_CHARGEMENT ne s'est pas...
4
                                                        NaT
. .
64
     \n\n \n\n----Rendez-vous d'origine----\nDe ...
                                                        NaT
    Bonjour, \n\nLa mise
                           disposition des donn es ... NaT
65
66
    Bonjour, \n\nLa mise
                           disposition des donn es ...
    Information de fin de RECETTE post-MEP\n\nde 1...
    Le traitement SID_CVLF_CHARGEMENT ne s'est pas... NaT
                                 from
                      Le Moal Mikael
0
             L'hotellier Jean-Marie
1
2
    DSI-suivi-production@netdmx.com
3
              no-reply@verlingue.fr
    DSI-suivi-production@netdmx.com
4
             L'hotellier Jean-Marie
64
              no-reply@verlingue.fr
65
66
              no-reply@verlingue.fr
67
                       Fralin Thomas
68
    DSI-suivi-production@netdmx.com
                                                      to
                                                                         Сc
                                                                             Cci
0
                                          DSI Infra DBA
                                                         DSI Data Factory
                            Allain Marc; Fresnel Julien
1
                                                                        NaN
                                                                             NaN
2
                                       DSI Data Factory
                                                                        NaN NaN
3
    DSI Data Factory; Generation Statistiques; Suppo...
                                                                      NaN NaN
4
                                       DSI Data Factory
                                                                        {\tt NaN}
                                                                             NaN
. .
64
                                         Fresnel Julien
                                                                        NaN
                                                                             NaN
65
                       DSI Data Factory; jvieaud@asi.fr
                                                                        {\tt NaN}
                                                                             NaN
66
    DSI Data Factory; Generation Statistiques; Suppo...
                                                                      NaN NaN
    MOA Verlingue; webmoa; DSSI Verlingue; DSI Presta...
67
                                                          DSI Management NaN
68
                                       DSI Data Factory
                                                                        NaN NaN
    Cat gories Crit re de diffusion Importance ... \
0
           NaN
                           Normal(e)
                                       Normal(e)
```

```
Normal(e) Normal(e)
1
           NaN
2
                           Normal(e) Normal(e)
           NaN
3
           NaN
                           Normal(e) Normal(e)
4
           NaN
                           Normal(e) Normal(e)
                                        ... ...
           NaN
                           Normal(e) Normal(e)
64
                           Normal(e) Normal(e) ...
65
           NaN
66
           NaN
                           Normal(e) Normal(e) ...
                           Normal(e) Normal(e) ...
67
           NaN
                           Normal(e) Normal(e) ...
68
           NaN
                                   structured_historic \
    [{'text': 'Bonjour,
La production et la pr...
    [{'text': 'Envoy : mardi 8 juin 2021 08:37
    [{'text': 'Le traitement SID_CVLF_CHARGEMENT n...
    [{'text': 'Bonjour,
La mise
         disposition des...
    [{'text': 'Le traitement SID_CVLF_CHARGEMENT n...
64 [{'text': '
----Rendez-vous d'origine---...
65 [{'text': 'Bonjour,
La mise
         disposition des...
66 [{'text': 'Bonjour,
La mise
          disposition des...
    [{'text': 'Information de fin de RECETTE post-...
   [{'text': 'Le traitement SID_CVLF_CHARGEMENT n...
                                       structured_body \
    [{'meta': {'date': None, 'from': None, 'to': N...
0
1
    [{'meta': {'date': None, 'from': 'Marie Leduc ...
    [{'meta': {'date': None, 'from': None, 'to': N...
2
3
    [{'meta': {'date': None, 'from': None, 'to': N...
    [{'meta': {'date': None, 'from': None, 'to': N...
   [{'meta': {'date': None, 'from': None, 'to': N...
```

```
[{'meta': {'date': None, 'from': None, 'to': N...
   [{'meta': {'date': None, 'from': None, 'to': N...
66
    [{'meta': {'date': None, 'from': None, 'to': N...
67
    [{'meta': {'date': None, 'from': None, 'to': N...
                                             last_body \
     La production et la proproduction PostgreSQL ...
0
1
    Envoy : mardi 8 juin 2021 08:37
                                      : L'hotelli...
2
    Le traitement SID CVLF CHARGEMENT ne s'est pas...
    La mise disposition des donn es du jour dans...
3
    Le traitement SID_CVLF_CHARGEMENT ne s'est pas...
4
64
                      ----Rendez-vous d'origine----
65
   La mise
             disposition des donn es du jour dans...
66
   La mise
             disposition des donn es du jour dans...
67
    Information de fin de RECETTE post-MEP de la V...
   Le traitement SID_CVLF_CHARGEMENT ne s'est pas...
                                             clean_body \
    la production et la prproduction postgresql se...
0
1
    envoy : flag_date_ flag_time_ : l'hotellie...
2
    le traitement sid cvlf chargement ne s'est pas...
    la mise disposition des donnes du jour dans le...
3
    le traitement sid_cvlf_chargement ne s'est pas...
4
. .
64
                                 rendez-vous d'origine
65
    la mise disposition des donnes du jour dans le...
    la mise disposition des donnes du jour dans le...
66
67
    information de fin de recette post-mep de la v...
    le traitement sid_cvlf_chargement ne s'est pas...
68
                                                 tokens extension hour min \
    [production, prproduction, postgresql, semble,...
0
                                                              0 NaN NaN
1
    [envoy, flag_date_, flag_time_, hotellier, fla...
                                                              0 NaN NaN
2
    [traitement, sid_cvlf_chargement, termin, corr...
                                                              1 NaN NaN
3
    [mise, disposition, donnes, jour, datawarehous...
                                                              2 NaN NaN
4
    [traitement, sid_cvlf_chargement, termin, corr...
                                                              1 NaN NaN
. .
64
                                [rendez-vous, origine]
                                                                0 NaN NaN
    [mise, disposition, donnes, jour, datawarehous...
                                                              2 NaN NaN
65
    [mise, disposition, donnes, jour, datawarehous...
                                                              2 NaN NaN
66
67
    [information, fin, recette, post-mep, version,...
                                                              0 NaN NaN
    [traitement, sid_cvlf_chargement, termin, corr...
                                                              1 NaN NaN
   dayofweek attachment_type
0
         NaN
                           [0]
1
                           [0]
         {\tt NaN}
```

```
2
                                   [0]
           {\tt NaN}
3
                                   [0]
           NaN
                                   [0]
4
           NaN
. .
                                   [0]
64
           NaN
                                   [0]
65
           NaN
66
           NaN
                                   [0]
                                   [0]
67
           NaN
           NaN
                                   [0]
68
```

[69 rows x 24 columns]

On réalise les mêmes concaténations que précédemment mais avec df_emails_tests et df_meta_tests

```
[14]: X_tests = pd.concat([df_emails_tests['clean_body'], df_meta_tests], axis=1)
[15]: X_tests
[15]:
                                                     clean_body
                                                                  extension__0 \
          la production et la prproduction postgresql se...
      0
                                                                            1
          envoy : flag_date_
                                  flag_time_ : l'hotellie...
                                                                            1
      1
          le traitement sid_cvlf_chargement ne s'est pas...
      2
                                                                            0
          la mise disposition des donnes du jour dans le...
      3
      4
          le traitement sid_cvlf_chargement ne s'est pas...
                                                                            0
      . .
      64
                                         rendez-vous d'origine
                                                                              1
      65
          la mise disposition des donnes du jour dans le...
                                                                            0
      66
          la mise disposition des donnes du jour dans le...
                                                                            0
          information de fin de recette post-mep de la v...
      67
                                                                            1
          le traitement sid_cvlf_chargement ne s'est pas...
          extension__1
                         extension__2
                                         extension__3
                                                        attachment_type__0
      0
                      0
                                     0
                                                     0
                                                                          1
                      0
                                     0
                                                     0
      1
                                                                          1
      2
                                     0
                                                     0
                                                                          1
                      1
      3
                      0
                                     1
                                                     0
                                                                          1
      4
                      1
                                     0
                                                     0
                                                                          1
                                                     0
      64
                      0
                                     0
                                                                          1
      65
                      0
                                     1
                                                     0
                                                                          1
      66
                      0
                                     1
                                                     0
                                                                          1
      67
                      0
                                     0
                                                     0
                                                                          1
      68
                      1
                                     0
                                                     0
                                                                          1
```

[69 rows x 6 columns]

Prédictions On réalise les prédictions :

```
[16]: yr = nn_model.predict(X_tests)
    yr2 = nn_model2.predict(X_tests)
    yr3 = nn_model3.predict(X_tests)
    yr4 = nn_model4.predict(X_tests)
    yr5 = nn_model5.predict(X_tests)
```

WARNING:tensorflow:5 out of the last 13 calls to <function
Model.make_predict_function.<locals>.predict_function at 0x000001FED68B9820>
triggered tf.function retracing. Tracing is expensive and the excessive number
of tracings could be due to (1) creating @tf.function repeatedly in a loop, (2)
passing tensors with different shapes, (3) passing Python objects instead of
tensors. For (1), please define your @tf.function outside of the loop. For (2),
@tf.function has experimental_relax_shapes=True option that relaxes argument
shapes that can avoid unnecessary retracing. For (3), please refer to https://ww
w.tensorflow.org/tutorials/customization/performance#python_or_tensor_args and
https://www.tensorflow.org/api_docs/python/tf/function for more details.

On applique le.inverse_transform pour changer les int en str

```
[17]: yr = le.inverse_transform(yr)
yr2 = le.inverse_transform(yr2)
yr3 = le.inverse_transform(yr3)
yr4 = le.inverse_transform(yr4)
yr5 = le.inverse_transform(yr5)
```

voici les résultats de chaque yr:

```
[18]: print("yr : ", yr)
    print("\n")
    print("\n")
    print("yr3 : ", yr3)
    print("\n")
    print("yr4 : ", yr4)
    print("\n")
    print("yr5 : ", yr5)
```

```
yr : ['production' 'production' 'production' 'datawarehouse' 'production' 'datawarehouse' 'production' 'production' 'production' 'production' 'production' 'production' 'production' 'production' 'production' 'datawarehouse' 'production' 'datawarehouse' 'production' 'production'
```

```
'production' 'datawarehouse' 'datawarehouse' 'production' 'production']
```

```
yr2 : ['production' 'production' 'production
```

```
yr3 : ['production' 'production' 'traitement' 'production' 'traitement' 'production' 'traitement' 'production' 'production
```

yr4: ['assistance' 'production' 'production' 'production' 'production' 'production' 'production' 'production' 'communication' 'assistance' 'production' 'communication' 'communication' 'communication' 'production' 'production' 'production' 'production' 'production' 'production' 'production' 'production' 'communication' 'production' 'production' 'communication' 'production' 'assistance'

```
'assistance' 'production' 'production' 'assistance' 'production'
 'assistance' 'production' 'assistance' 'production' 'production'
 'production' 'assistance' 'communication' 'assistance' 'production'
 'production' 'production' 'production']
yr5 : ['production' 'production' 'rdv' 'production' 'traitement'
 'traitement' 'assistance' 'assistance' 'personnel' 'production'
 'production' 'rdv' 'personnel' 'production' 'production' 'traitement'
 'datawarehouse' 'traitement' 'production' 'rdv' 'production' 'rdv'
 'traitement' 'traitement' 'production' 'rdv' 'production' 'production'
 'personnel' 'personnel' 'personnel' 'production' 'production' 'personnel'
 'personnel' 'production' 'traitement' 'production' 'personnel'
 'traitement' 'traitement' 'personnel' 'assistance' 'production'
 'personnel' 'rdv' 'production' 'assistance' 'personnel' 'personnel'
 'production' 'assistance' 'personnel' 'production' 'production'
 'production' 'datawarehouse' 'production' 'production' 'production'
 'assistance' 'rdv' 'datawarehouse' 'rdv' 'traitement' 'traitement' 'rdv'
 'production']
```

On remarque que les prédictions se sont faite, néanmoins elles ne sont pas exactes. Tentons de se rapprocher des bons résultats.

1.0.6 Bonus (80 époques pour le cnn_model)

```
[19]: nn_model6 = NeuralModel(architecture_function= cnn_model,__
   opretrained_embedding=pretrained_embedding, text_input_column_
   ⇒="clean_body",meta_input_list=['extension', 'dayofweek','hour', 'min',⊔
   nn_model6.fit(X,y)
  Epoch 1/80
  0.1304
  Epoch 2/80
  0.1014
  Epoch 3/80
  0.2174
  Epoch 4/80
  0.2319
  Epoch 5/80
  0.2029
  Epoch 6/80
```

```
0.1884
Epoch 7/80
0.2464
Epoch 8/80
0.2029
Epoch 9/80
0.2464
Epoch 10/80
0.2899
Epoch 11/80
0.3188
Epoch 12/80
0.2464
Epoch 13/80
0.3333
Epoch 14/80
0.3333
Epoch 15/80
0.2464
Epoch 16/80
0.3478
Epoch 17/80
0.4058
Epoch 18/80
0.4203
Epoch 19/80
0.3478
Epoch 20/80
0.4203
Epoch 21/80
0.4058
Epoch 22/80
```

```
0.4348
Epoch 23/80
0.5217
Epoch 24/80
0.3913
Epoch 25/80
0.4783
Epoch 26/80
0.4783
Epoch 27/80
0.5507
Epoch 28/80
0.4783
Epoch 29/80
0.4928
Epoch 30/80
0.5072
Epoch 31/80
0.5072
Epoch 32/80
0.4783
Epoch 33/80
0.4638
Epoch 34/80
0.5362
Epoch 35/80
0.5072
Epoch 36/80
0.5507
Epoch 37/80
0.5507
Epoch 38/80
```

```
0.6087
Epoch 39/80
0.5797
Epoch 40/80
0.6377
Epoch 41/80
0.6377
Epoch 42/80
0.6232
Epoch 43/80
0.6087
Epoch 44/80
0.5362
Epoch 45/80
0.6522
Epoch 46/80
0.6812
Epoch 47/80
0.6667
Epoch 48/80
0.7101
Epoch 49/80
0.7246
Epoch 50/80
0.6667
Epoch 51/80
0.7536
Epoch 52/80
0.7826
Epoch 53/80
0.8116
Epoch 54/80
```

```
0.7971
Epoch 55/80
0.7101
Epoch 56/80
0.7826
Epoch 57/80
0.8986
Epoch 58/80
0.8551
Epoch 59/80
0.8551
Epoch 60/80
0.8261
Epoch 61/80
0.8841
Epoch 62/80
0.8551
Epoch 63/80
0.9275
Epoch 64/80
0.8986
Epoch 65/80
0.8841
Epoch 66/80
0.9130
Epoch 67/80
0.9275
Epoch 68/80
0.8841
Epoch 69/80
0.8551
Epoch 70/80
```

```
Epoch 71/80
 0.9130
 Epoch 72/80
 0.9565
 Epoch 73/80
 0.9130
 Epoch 74/80
 0.9275
 Epoch 75/80
 0.9130
 Epoch 76/80
 0.9710
 Epoch 77/80
 0.9275
 Epoch 78/80
 0.9130
 Epoch 79/80
 0.9565
 Epoch 80/80
 1.0000
[20]: yr6 = nn_model6.predict(X_tests)
 yr6 = le.inverse_transform(yr6)
 WARNING:tensorflow:5 out of the last 13 calls to <function
```

0.9275

WARNING:tensorflow:5 out of the last 13 calls to <function
Model.make_predict_function.<locals>.predict_function at 0x000001FEDB877DC0>
triggered tf.function retracing. Tracing is expensive and the excessive number
of tracings could be due to (1) creating @tf.function repeatedly in a loop, (2)
passing tensors with different shapes, (3) passing Python objects instead of
tensors. For (1), please define your @tf.function outside of the loop. For (2),
@tf.function has experimental_relax_shapes=True option that relaxes argument
shapes that can avoid unnecessary retracing. For (3), please refer to https://ww
w.tensorflow.org/tutorials/customization/performance#python_or_tensor_args and
https://www.tensorflow.org/api_docs/python/tf/function for more details.

On va rajouter la colonne "label" au jeu de tests pour comparer avec les résultats théoriques :

```
[22]: yr_label = list()
      for i in range(len(yr)):
          yr_label.append(yr[i])
      df_label = pd.DataFrame(yr_label)
      df_label.columns = ['label']
      df_result = pd.concat([df_emails, df_label['label']], axis=1)
[23]:
     df_emails
[23]:
                                                      header \
      0
              Probl me connexion Prod et pr prod postgresql
          TR: package open source traitement des emails ...
      1
      2
          RE7_Coverlife/TALEND_BI_COVERLIFE/SID_CVLF_CHA...
                                 DWH ADP OK - GENERATION_PRD
      3
      4
          RE7_Coverlife/TALEND_BI_COVERLIFE/SID_CVLF_CHA...
                    TR: Gestion de la BAL Verlingue Connect
      64
      65
                                  DWH ADP OK - VERLINGUE_PRD
      66
                                 DWH ADP OK - GENERATION_PRD
      67
          [MEP de Version MAJEURE 2021.V2.0] - [FIN DE R...
          RE7_Coverlife/TALEND_BI_COVERLIFE/SID_CVLF_CHA...
                                                         body date \
          Bonjour, \n\n \n\nLa production et la pr produc... NaT
      0
           \n\n \n\nDe : Marie Leduc <mleduc@quantmetry... NaT
      1
      2
          Le traitement SID CVLF CHARGEMENT ne s'est pas...
          Bonjour, \n\nLa mise disposition des donn es ...
      3
          Le traitement SID_CVLF_CHARGEMENT ne s'est pas...
      4
                                                             NaT
           \n\n \n\n----Rendez-vous d'origine----\nDe ...
      64
      65
          Bonjour, \n\nLa mise
                                disposition des donn es ... NaT
          Bonjour, \n\nLa mise
                                disposition des donn es ... NaT
      66
          Information de fin de RECETTE post-MEP\n\nde 1...
      67
          Le traitement SID_CVLF_CHARGEMENT ne s'est pas... NaT
                                      from \
                            Le Moal Mikael
      0
      1
                   L'hotellier Jean-Marie
      2
          DSI-suivi-production@netdmx.com
      3
                    no-reply@verlingue.fr
          DSI-suivi-production@netdmx.com
      4
                   L'hotellier Jean-Marie
      64
      65
                    no-reply@verlingue.fr
```

```
66
               no-reply@verlingue.fr
67
                       Fralin Thomas
68
    DSI-suivi-production@netdmx.com
                                                       to
                                                                          Cc Cci \
                                                                              {\tt NaN}
0
                                           DSI Infra DBA DSI Data Factory
1
                             Allain Marc; Fresnel Julien
                                                                         NaN
                                                                              NaN
2
                                       DSI Data Factory
                                                                         NaN NaN
3
                                                                       NaN NaN
    DSI Data Factory; Generation Statistiques; Suppo...
                                       DSI Data Factory
4
                                                                         \mathtt{NaN}
                                                                              NaN
. .
64
                                          Fresnel Julien
                                                                              NaN
                                                                         NaN
65
                       DSI Data Factory; jvieaud@asi.fr
                                                                         {\tt NaN}
                                                                              NaN
66
    DSI Data Factory; Generation Statistiques; Suppo...
                                                                       NaN NaN
    MOA Verlingue; webmoa; DSSI Verlingue; DSI Presta...
67
                                                                           {\tt NaN}
                                                           DSI Management
68
                                        DSI Data Factory
                                                                         \mathtt{NaN}
    Cat gories Crit re de diffusion Importance
0
           NaN
                            Normal(e)
                                       Normal(e)
           NaN
                            Normal(e)
1
                                       Normal(e)
2
           NaN
                            Normal(e) Normal(e)
3
           NaN
                            Normal(e)
                                       Normal(e)
4
                            Normal(e)
                                       Normal(e)
           NaN
. .
           NaN
                            Normal(e)
                                       Normal(e)
64
65
           NaN
                            Normal(e)
                                       Normal(e)
66
           NaN
                            Normal(e)
                                       Normal(e)
                            Normal(e) Normal(e)
67
           NaN
68
           NaN
                            Normal(e)
                                       Normal(e)
                                        structured_body \
    [{'meta': {'date': None, 'from': None, 'to': N...
0
    [{'meta': {'date': None, 'from': 'Marie Leduc ...
1
    [{'meta': {'date': None, 'from': None, 'to': N...
2
3
    [{'meta': {'date': None, 'from': None, 'to': N...
4
    [{'meta': {'date': None, 'from': None, 'to': N...
    [{'meta': {'date': None, 'from': None, 'to': N...
64
    [{'meta': {'date': None, 'from': None,
65
                                              'to': N...
    [{'meta': {'date': None, 'from': None, 'to': N...
66
    [{'meta': {'date': None, 'from': None, 'to': N...
67
    [{'meta': {'date': None, 'from': None, 'to': N...
                                               last_body \
0
     La production et la proproduction PostgreSQL ...
    Envoy: mardi 8 juin 2021 08:37
1
                                         : L'hotelli...
2
    Le traitement SID_CVLF_CHARGEMENT ne s'est pas...
```

```
3
             disposition des donn es du jour dans...
    Le traitement SID_CVLF_CHARGEMENT ne s'est pas...
4
. .
                      ----Rendez-vous d'origine----
64
              disposition des donn es du jour dans...
65
   La mise
              disposition des donn es du jour dans...
66
   La mise
    Information de fin de RECETTE post-MEP de la V...
67
   Le traitement SID_CVLF_CHARGEMENT ne s'est pas...
                                             clean body \
0
    la production et la prproduction postgresql se...
    envoy : flag_date_
                          flag_time_ : l'hotellie...
1
2
    le traitement sid_cvlf_chargement ne s'est pas...
3
    la mise disposition des donnes du jour dans le...
4
    le traitement sid_cvlf_chargement ne s'est pas...
                                 rendez-vous d'origine
64
    la mise disposition des donnes du jour dans le...
65
    la mise disposition des donnes du jour dans le...
    information de fin de recette post-mep de la v...
67
    le traitement sid_cvlf_chargement ne s'est pas...
                                                 tokens \
0
    [production, prproduction, postgresql, semble,...
    [envoy, flag_date_, flag_time_, hotellier, fla...
1
2
    [traitement, sid_cvlf_chargement, termin, corr...
3
    [mise, disposition, donnes, jour, datawarehous...
4
    [traitement, sid_cvlf_chargement, termin, corr...
64
                                [rendez-vous, origine]
    [mise, disposition, donnes, jour, datawarehous...
65
    [mise, disposition, donnes, jour, datawarehous...
66
67
    [information, fin, recette, post-mep, version,...
68
    [traitement, sid_cvlf_chargement, termin, corr...
                                               keywords extension hour min \
    [prproduction, flag_date_, vers, flag_time_, c...
0
                                                              0 NaN NaN
1
    [flag_date_, flag_time_, hotellier, flag_name_...
                                                              0 NaN NaN
2
    [traitement, sid_cvlf_chargement, suivi, produ...
                                                              1 NaN NaN
3
        [atlas, nombre, flag_cp_, flag_date_, pouvez]
                                                                 2 NaN NaN
4
    [traitement, sid_cvlf_chargement, suivi, produ...
                                                              1 NaN NaN
. .
64
                                              [origine]
                                                                0 NaN NaN
65
     [nombre, flag_cp_, flag_date_, gnration, pouvez]
                                                                2 NaN NaN
66
    [nombre, flag_phone_, flag_cp_, flag_date_, po...
                                                              2 NaN NaN
       [flag_time_, tnr, flag_name_, iard, flag_url_]
67
                                                                0 NaN NaN
68
    [traitement, sid_cvlf_chargement, suivi, produ...
                                                              1 NaN NaN
```

```
dayofweek attachment_type
      0
               NaN
                                 [0]
      1
               NaN
      2
               NaN
                                 [0]
      3
               NaN
                                 [0]
      4
               NaN
                                 [0]
                                 [0]
      64
               NaN
      65
                                 [0]
               NaN
      66
               NaN
                                 [0]
      67
               NaN
                                 [0]
      68
               NaN
                                 [0]
      [69 rows x 26 columns]
[25]:
     df_result
[25]:
                                                        header \
      0
              Probl me connexion Prod et pr prod postgresql
      1
          TR: package open source traitement des emails ...
      2
          RE7_Coverlife/TALEND_BI_COVERLIFE/SID_CVLF_CHA...
      3
                                  DWH ADP OK - GENERATION_PRD
      4
          RE7_Coverlife/TALEND_BI_COVERLIFE/SID_CVLF_CHA...
      . .
      64
                     TR: Gestion de la BAL Verlingue Connect
      65
                                   DWH ADP OK - VERLINGUE_PRD
      66
                                  DWH ADP OK - GENERATION_PRD
      67
          [MEP de Version MAJEURE 2021.V2.0] - [FIN DE R...
          RE7_Coverlife/TALEND_BI_COVERLIFE/SID_CVLF_CHA...
      68
                                                          body date \
      0
          Bonjour, \n\n \n\nLa production et la pr produc... NaT
      1
           \n\n \n\nDe : Marie Leduc <mleduc@quantmetry...
          Le traitement SID_CVLF_CHARGEMENT ne s'est pas...
      2
      3
          Bonjour, \n\nLa mise disposition des donn es ... NaT
          Le traitement SID_CVLF_CHARGEMENT ne s'est pas...
      4
                                                              NaT
      64
           \n\n \n\n----Rendez-vous d'origine----\nDe ...
                                                              NaT
      65
          Bonjour, \n\nLa mise
                                 disposition des donn es ... NaT
          Bonjour, \n\nLa mise
                                 disposition des donn es ...
      66
          Information de fin de RECETTE post-MEP\n\nde 1...
          Le traitement SID_CVLF_CHARGEMENT ne s'est pas...
                                       from
      0
                            Le Moal Mikael
```

L'hotellier Jean-Marie

1

```
2
    DSI-suivi-production@netdmx.com
3
               no-reply@verlingue.fr
4
    DSI-suivi-production@netdmx.com
. .
              L'hotellier Jean-Marie
64
               no-reply@verlingue.fr
65
               no-reply@verlingue.fr
66
                       Fralin Thomas
67
    DSI-suivi-production@netdmx.com
68
                                                       to
                                                                          Cc Cci
0
                                           DSI Infra DBA
                                                          DSI Data Factory
                                                                              NaN
1
                             Allain Marc; Fresnel Julien
                                                                              NaN
2
                                        DSI Data Factory
                                                                         NaN NaN
3
    DSI Data Factory; Generation Statistiques; Suppo...
                                                                       NaN NaN
4
                                        DSI Data Factory
                                                                         NaN
                                                                              NaN
. .
64
                                          Fresnel Julien
                                                                         NaN
                                                                              NaN
65
                       DSI Data Factory; jvieaud@asi.fr
                                                                         {\tt NaN}
                                                                             NaN
    DSI Data Factory; Generation Statistiques; Suppo...
66
                                                                       NaN NaN
67
    MOA Verlingue; webmoa; DSSI Verlingue; DSI Presta...
                                                           DSI Management
                                                                            {\tt NaN}
68
                                       DSI Data Factory
                                                                         NaN NaN
    Cat gories Crit re de diffusion Importance ...
0
                            Normal(e)
                                       Normal(e)
           NaN
1
           NaN
                            Normal(e)
                                       Normal(e)
                            Normal(e)
2
           NaN
                                       Normal(e)
3
                            Normal(e)
           NaN
                                       Normal(e)
4
           NaN
                            Normal(e)
                                       Normal(e)
                            Normal(e)
                                       Normal(e)
64
           NaN
                            Normal(e)
                                       Normal(e)
65
           NaN
66
           NaN
                            Normal(e)
                                        Normal(e)
67
           NaN
                            Normal(e)
                                       Normal(e)
68
                            Normal(e)
                                       Normal(e)
           NaN
                                               last_body \
0
     La production et la proproduction PostgreSQL ...
1
    Envoy: mardi 8 juin 2021 08:37
                                         : L'hotelli...
    Le traitement SID_CVLF_CHARGEMENT ne s'est pas...
2
3
              disposition des donn es du jour dans...
4
    Le traitement SID_CVLF_CHARGEMENT ne s'est pas...
. .
64
                      ----Rendez-vous d'origine----
65
              disposition des donn es du jour dans...
    La mise
              disposition des donn es du jour dans...
66
    La mise
    Information de fin de RECETTE post-MEP de la V...
```

68 Le traitement SID_CVLF_CHARGEMENT ne s'est pas... clean_body \ 0 la production et la prproduction postgresql se... envoy : flag_date_ flag_time_ : l'hotellie... 1 2 le traitement sid_cvlf_chargement ne s'est pas... la mise disposition des donnes du jour dans le... 3 4 le traitement sid_cvlf_chargement ne s'est pas... . . 64 rendez-vous d'origine 65 la mise disposition des donnes du jour dans le... la mise disposition des donnes du jour dans le... 66 67 information de fin de recette post-mep de la v... le traitement sid_cvlf_chargement ne s'est pas... tokens \ 0 [production, prproduction, postgresql, semble,... [envoy, flag_date_, flag_time_, hotellier, fla... 1 2 [traitement, sid_cvlf_chargement, termin, corr... [mise, disposition, donnes, jour, datawarehous... 3 4 [traitement, sid_cvlf_chargement, termin, corr... 64 [rendez-vous, origine] 65 [mise, disposition, donnes, jour, datawarehous... [mise, disposition, donnes, jour, datawarehous... 66 67 [information, fin, recette, post-mep, version,... 68 [traitement, sid_cvlf_chargement, termin, corr... keywords extension hour min \ [prproduction, flag_date_, vers, flag_time_, c... 0 0 NaN NaN [flag_date_, flag_time_, hotellier, flag_name_... 1 0 NaN NaN 2 [traitement, sid_cvlf_chargement, suivi, produ... 1 NaN NaN 3 [atlas, nombre, flag_cp_, flag_date_, pouvez] 2 NaN NaN 4 [traitement, sid_cvlf_chargement, suivi, produ... 1 NaN NaN . . 64 [origine] 0 NaN NaN [nombre, flag_cp_, flag_date_, gnration, pouvez] 65 2 NaN NaN 66 2 NaN NaN [nombre, flag_phone_, flag_cp_, flag_date_, po... [flag_time_, tnr, flag_name_, iard, flag_url_] 67 0 NaN NaN [traitement, sid_cvlf_chargement, suivi, produ... 1 NaN NaN

label	attachment_type	dayofweek	
production	[0]	NaN	0
production	[0]	NaN	1
production	[0]	NaN	2
datawarehouse	[0]	NaN	3
production	[0]	NaN	4

```
[0]
64
          NaN
                                     production
65
          NaN
                            [0]
                                 datawarehouse
66
          NaN
                            [0]
                                  datawarehouse
          NaN
                            [0]
67
                                     production
68
          NaN
                            [0]
                                     production
```

[69 rows x 27 columns]

Les résultats sont curieusement moins exacts sur les **Notebooks** par rapport aux tests effectués sur via **PyCharm**

Résultats obtenus via Pycharm

```
[26]: df_emails_pycharm = pd.read_csv(r"C:\Users\JUFL\Desktop\test3.CSV", delimiter=";
```

```
[28]: df_emails_pycharm
```

```
[28]:
          Unnamed: 0
                                                                    header \
                   0
      0
                           Probl me connexion Prod et pr prod postgresql
      1
                    1
                       TR: package open source traitement des emails ...
      2
                    2
                       RE7 Coverlife/TALEND BI COVERLIFE/SID CVLF CHA...
      3
                    3
                                              DWH ADP OK - GENERATION PRD
                       RE7_Coverlife/TALEND_BI_COVERLIFE/SID_CVLF_CHA...
      4
      64
                   64
                                 TR: Gestion de la BAL Verlingue Connect
                                               DWH ADP OK - VERLINGUE_PRD
      65
                   65
                   66
                                              DWH ADP OK - GENERATION_PRD
      66
      67
                   67
                       [MEP de Version MAJEURE 2021.V2.0] - [FIN DE R...
      68
                       RE7_Coverlife/TALEND_BI_COVERLIFE/SID_CVLF_CHA...
                                                          body date
```

```
0
    Bonjour, \n\n \n\nLa production et la pr produc...
                                                         NaN
1
     \n\n \n\nDe : Marie Leduc <mleduc@quantmetry...
                                                        NaN
2
    Le traitement SID_CVLF_CHARGEMENT ne s'est pas...
                                                         NaN
3
    Bonjour, \n\nLa mise disposition des donn es ...
                                                         NaN
    Le traitement SID_CVLF_CHARGEMENT ne s'est pas...
4
                                                         NaN
. .
64
     \n\n \n\n----Rendez-vous d'origine----\nDe ...
                                                         NaN
    Bonjour, \n\nLa mise
65
                           disposition des donn es ...
                                                        NaN
    Bonjour, \n\nLa mise
                           disposition des donn es ...
66
                                                        NaN
    Information de fin de RECETTE post-MEP\n\nde l...
67
                                                         NaN
    Le traitement SID_CVLF_CHARGEMENT ne s'est pas...
                                                         NaN
```

from \
0 Le Moal Mikael
1 L'hotellier Jean-Marie

```
2
    DSI-suivi-production@netdmx.com
3
              no-reply@verlingue.fr
4
    DSI-suivi-production@netdmx.com
. .
             L'hotellier Jean-Marie
64
65
              no-reply@verlingue.fr
66
              no-reply@verlingue.fr
67
                       Fralin Thomas
    DSI-suivi-production@netdmx.com
68
                                                      to
                                                                          Cc Cci
0
                                          DSI Infra DBA DSI Data Factory
                                                                              NaN
1
                            Allain Marc; Fresnel Julien
                                                                         NaN
                                                                              NaN
2
                                       DSI Data Factory
                                                                         NaN NaN
3
    DSI Data Factory; Generation Statistiques; Suppo...
                                                                      NaN NaN
4
                                       DSI Data Factory
                                                                         NaN
                                                                              NaN
. .
64
                                         Fresnel Julien
                                                                         NaN
                                                                              NaN
65
                       DSI Data Factory; jvieaud@asi.fr
                                                                         NaN NaN
    DSI Data Factory; Generation Statistiques; Suppo...
66
                                                                      NaN NaN
    MOA Verlingue; webmoa; DSSI Verlingue; DSI Presta...
67
                                                           DSI Management
                                                                           {\tt NaN}
                                       DSI Data Factory
68
                                                                         NaN NaN
    Cat gories Crit re de diffusion ...
0
           NaN
                           Normal(e)
1
           NaN
                           Normal(e)
                           Normal(e)
2
           NaN
3
           NaN
                           Normal(e)
4
           NaN
                           Normal(e)
                           Normal(e)
64
           NaN
                           Normal(e)
65
           NaN
                           Normal(e)
66
           NaN
67
           NaN
                           Normal(e)
68
           NaN
                           Normal(e)
                                        structured_body \
0
    [{'meta': {'date': None, 'from': None, 'to': N...
    [{'meta': {'date': None, 'from': 'Marie Leduc ...
1
2
    [{'meta': {'date': None, 'from': None, 'to': N...
    [{'meta': {'date': None, 'from': None, 'to': N...
3
4
    [{'meta': {'date': None, 'from': None, 'to': N...
. .
64
    [{'meta': {'date': None, 'from': None, 'to': N...
    [{'meta': {'date': None, 'from': None, 'to': N...
65
    [{'meta': {'date': None, 'from': None, 'to': N...
66
    [{'meta': {'date': None, 'from': None, 'to': N...
67
```

```
[{'meta': {'date': None, 'from': None, 'to': N...
                                              last body \
0
     La production et la proproduction PostgreSQL ...
    Envoy : mardi 8 juin 2021 08:37
1
                                       : L'hotelli...
2
    Le traitement SID_CVLF_CHARGEMENT ne s'est pas...
3
    La mise disposition des donn es du jour dans...
4
    Le traitement SID_CVLF_CHARGEMENT ne s'est pas...
. .
                      ----Rendez-vous d'origine----
64
65
   La mise
              disposition des donn es du jour dans...
              disposition des donn es du jour dans...
66
   La mise
67
    Information de fin de RECETTE post-MEP de la V...
68 Le traitement SID_CVLF_CHARGEMENT ne s'est pas...
                                             clean_body \
    la production et la prproduction postgresql se...
0
1
    envoy : flag_date_
                           flag_time_ : l'hotellie...
    le traitement sid_cvlf_chargement ne s'est pas...
    la mise disposition des donnes du jour dans le...
4
    le traitement sid_cvlf_chargement ne s'est pas...
64
                                 rendez-vous d'origine
65
    la mise disposition des donnes du jour dans le...
    la mise disposition des donnes du jour dans le...
    information de fin de recette post-mep de la v...
    le traitement sid_cvlf_chargement ne s'est pas...
                                                 tokens
                                                         extension hour min \
    ['production', 'prproduction', 'postgresql', '...
0
                                                                0 NaN NaN
    ['envoy', 'flag_date_', 'flag_time_', 'hotelli...
1
                                                                   NaN NaN
    ['traitement', 'sid_cvlf_chargement', 'termin'...
2
                                                                   NaN NaN
3
    ['mise', 'disposition', 'donnes', 'jour', 'dat...
                                                                   NaN NaN
                                                                2
4
    ['traitement', 'sid_cvlf_chargement', 'termin'...
                                                                1
                                                                   NaN NaN
. .
64
                            ['rendez-vous', 'origine']
                                                                  0 NaN NaN
    ['mise', 'disposition', 'donnes', 'jour', 'dat...
65
                                                                2 NaN NaN
    ['mise', 'disposition', 'donnes', 'jour', 'dat...
66
                                                                2 NaN NaN
    ['information', 'fin', 'recette', 'post-mep', ...
67
                                                                0 NaN NaN
    ['traitement', 'sid_cvlf_chargement', 'termin'...
                                                                1 NaN NaN
   dayofweek attachment_type
                                       label
0
         NaN
                          [0]
                                  production
1
         NaN
                          [0]
                                   personnel
2
                          [0]
         {\tt NaN}
                                  traitement
3
         NaN
                          [0]
                               datawarehouse
4
         NaN
                          [0]
                                  traitement
```

```
[0]
64
                                                   rdv
           {\tt NaN}
                                [0]
65
           {\tt NaN}
                                      datawarehouse
                                [0]
                                      datawarehouse
66
           NaN
67
           {\tt NaN}
                                [0]
                                          production
           NaN
                                [0]
                                          traitement
68
```

[69 rows x 26 columns]

Comparons les réultats obtenus via Pycharm avec les résultats théoriques:

89.86 % of accuracy